

Modelado y Simulación para la Predicción del Mundial FIFA 2026 Usando Machine Learning

Carlos David Ascencio Acarca, *Bachiller*, aa15009@ues.edu.sv, UES y Eduardo David Rodriguez Ventura, *Bachiller*, rv15001@ues.edu.sv, UES

Resumen— La predicción de resultados deportivos representa un problema complejo debido a la naturaleza dinámica e incierta del fútbol profesional. En este trabajo se desarrolla un pipeline de Machine Learning orientado a estimar probabilidades de victoria en partidos internacionales y simular el torneo completo de la Copa Mundial FIFA 2026 mediante técnicas de Monte Carlo.

Para el desarrollo del sistema se utilizaron datos históricos de partidos internacionales y ratings ELO de selecciones nacionales. A partir de estos datos se construyó un dataset a nivel de partido, incorporando variables relacionadas con diferencia ELO, localía, resultados recientes y degradación temporal de información histórica.

Se implementaron modelos de clasificación multiclase, incluyendo Regresión Logística y XGBoost, evaluados mediante métricas probabilísticas como Log Loss y Brier Score. Posteriormente, las probabilidades generadas fueron utilizadas para simular miles de ediciones completas del Mundial 2026 bajo el nuevo formato de 48 selecciones.

Palabras clave: Machine Learning, XGBoost, Monte Carlo, FIFA World Cup 2026, ELO Rating, Predicción Deportiva.

I. INTRODUCCIÓN

La predicción de resultados deportivos ha ganado gran relevancia dentro del área de analítica deportiva y debido al crecimiento exponencial de datos disponibles [5][7], el Machine Learning puede ser una herramienta muy poderosa para desarrollar modelos predictivos robustos en competiciones profesionales.

La Copa Mundial FIFA 2026 introduce un nuevo reto estructural debido al cambio de 32 a 48 selecciones nacionales [6], modificando la dinámica histórica de clasificación y eliminación.

En este proyecto se propone un enfoque basado en Machine Learning supervisado para estimar probabilidades de resultado a nivel de partido y posteriormente utilizar dichas probabilidades en una simulación Monte Carlo para modelar múltiples escenarios del Mundial FIFA 2026.

II. TRABAJOS RELACIONADOS

Diversos enfoques han utilizado estadísticas históricas, rankings, métricas avanzadas y simulaciones probabilísticas para modelar resultados deportivos.

El sistema ELO o ELO rating ha demostrado gran efectividad para representar fortaleza relativa entre selecciones debido a su capacidad para incorporar calidad del rival, diferencia de goles y localía.

Por otro lado, algoritmos de aprendizaje supervisado como Regresión Logística, Random Forest y XGBoost han demostrado alta efectividad en problemas de clasificación tabular. Particularmente, XGBoost [4] ha mostrado excelentes resultados en escenarios deportivos debido a su capacidad para capturar relaciones no lineales y patrones complejos.

Asimismo, las simulaciones Monte Carlo han sido ampliamente utilizadas para modelar torneos deportivos completos mediante repetición probabilística de escenarios posibles. Este enfoque permite estimar probabilidades de clasificación, avance y campeonato a partir de probabilidades individuales de partidos.

III. METODOLOGIA

A. Recolección de Datos

Para el desarrollo del proyecto se utilizaron dos conjuntos principales de datos:

1. Resultados históricos de partidos internacionales [2].
2. Ratings ELO históricos de selecciones nacionales [3][6].

El dataset de resultados históricos contiene información relacionada con:

- Fecha del partido.
- Equipo local.
- Equipo visitante.
- Goles anotados.
- Torneo.
- Localía neutral.

Por otra parte, el dataset ELO rating proporciona un indicador dinámico de fortaleza relativa entre selecciones nacionales.

B. Preprocesamiento de Datos

Los datos fueron ordenados cronológicamente para preservar la consistencia temporal del problema predictivo.

Se realizaron procesos de:

- Conversión de fechas.
- Eliminación de valores nulos.
- Eliminación de duplicados.
- Estandarización de nombres de selecciones.
- Construcción de variables objetivo.

La variable objetivo fue definida como un problema de clasificación multiclase:

- 0: Victoria local.
- 1: Empate.
- 2: Victoria visitante.

Este enfoque evita problemas severos de desbalance de clases que ocurrirían si se modelara directamente el campeón del torneo.

C. Ingeniería de Características

La ingeniería de características representa una de las etapas más importantes del proyecto.

Se construyeron variables relacionadas con:

1. Diferencia ELO

La diferencia ELO fue calculada mediante:

$$\text{elo_diff} = \text{eloA} - \text{eloB} \quad (1)$$

Esta variable permite representar la diferencia relativa de fortaleza entre selecciones.

2. Forma reciente

La forma reciente fue calculada utilizando los últimos partidos previos de cada selección, evitando utilizar información futura y reduciendo problemas de data leakage.

3. Degradación Temporal (Time Decay)

Con el objetivo de otorgar mayor importancia a partidos recientes, se implementó un mecanismo de decay exponencial:

$$w = e^{\{-\lambda t\}} \quad (2)$$

Donde:

- (w) representa el peso temporal.
- (t) representa el tiempo transcurrido.
- (λ) controla la velocidad de degradación.

Este enfoque permite reducir el impacto predictivo de partidos muy antiguos.

D. Análisis Exploratorio de Datos (EDA)

Se realizaron múltiples análisis exploratorios para comprender la distribución y comportamiento de los datos.

Entre las principales visualizaciones desarrolladas se incluyen:

- Distribución de resultados.




Ilustración 1. Distribución de Resultados

- Distribución de diferencia ELO.




Ilustración 2. Diferencia de ELO

- Heatmap de correlaciones.




Ilustración 3. Matriz de Correlación

Como parte fundamental en el diseño de esta arquitectura predictiva, se evaluó la colinealidad y la fuerza estadística de las variables construidas frente a la variable objetivo (resultado del partido). Para ello, se generó una Matriz de Correlación de Pearson (ver Figura), la cual revela hallazgos determinantes empíricos para la selección del algoritmo de Machine Learning:

Supremacía Predictiva del Sistema ELO: La variable construida `elo_difference` presenta la correlación lineal más fuerte con el objetivo (0.46). En el contexto de la predicción deportiva, donde la varianza y el componente de azar son estadísticamente altos, una correlación de esta magnitud justifica la adopción de un motor dinámico de ELO por encima del uso de métricas estáticas o rankings tradicionales. A mayor diferencia de ELO a favor del equipo local, la probabilidad empírica de una victoria local aumenta significativamente.

Impacto de la Calidad Individual: Al desagregar la métrica, se observa que la calidad del equipo visitante (`away_elo`) tiene un impacto disruptivo ligeramente superior (-0.27) sobre el resultado en comparación con la calidad del equipo local (`home_elo`, con 0.24). Esto confirma la premisa de que enfrentar a un rival de alta jerarquía penaliza severamente las probabilidades de victoria del local.

Aislamiento del Contexto: Las variables de contexto muestran una correlación lineal aislada marginal. La ventaja de localía (home_advantage) presenta un valor de 0.07, mientras que el carácter amistoso del encuentro (is_friendly) es estadísticamente nulo frente al resultado (-0.01). Sin embargo, se conservaron en el dataset debido a que los modelos basados en ensambles de árboles pueden extraer valor predictivo no lineal al combinar estas variables con el ELO en nodos profundos.

Gestión de la Multicolinealidad: La matriz revela una alta multicolinealidad-esperada entre elo_difference y sus componentes generadores (0.57 y -0.55). Aunque esta característica violaría los supuestos de modelos paramétricos como la Regresión Lineal o Logística tradicional, justifica técnica y matemáticamente la elección de XGBoost como motor principal. Los algoritmos basados en Gradient Boosting son inherentemente robustos frente a características altamente correlacionadas, permitiendo la retención de todas las variables sin comprometer la estabilidad del sistema ni sufrir de inflación de la varianza.

- Visualización del decay temporal.




Ilustración 4. Decay Temporal

El análisis mostró que:

- Existe una ventaja significativa para equipos locales.
- La diferencia ELO posee fuerte relación con el resultado del partido.
- Los datos históricos antiguos poseen menor relevancia predictiva.

E. División Temporal de Datos

Con el objetivo de simular correctamente predicción futura, se utilizó una separación temporal:

- Entrenamiento 1995–2018
- Validación 2019–2022
- Prueba 2023–2025

Este enfoque evita fugas de información y mejora la validez experimental.

IV. MODELOS IMPLEMENTADOS

Se implementaron dos modelos principales:

- 1) Regresión Logística

Utilizada como baseline debido a su simplicidad e interpretabilidad estadística.

- 2) XGBoost

Seleccionado como modelo principal debido a:

- Capacidad para manejar datos tabulares.
- Captura de relaciones no lineales.
- Alto desempeño en problemas deportivos.

- Buena capacidad predictiva.

Se aplicó búsqueda de hiperparámetros utilizando RandomizedSearchCV.

Debido a la naturaleza probabilística del problema, no se utilizó accuracy como métrica principal.

Las métricas seleccionadas fueron:

- 1) Log Loss

$$\text{LogLoss} = -\frac{1}{N} \sum y \log(p) \quad (3)$$

Esta métrica penaliza predicciones excesivamente confiadas incorrectas.

- 2) Brier Score

$$BS = \frac{1}{N} \sum (f - o)^2 \quad (4)$$

Esta métrica evalúa la calibración probabilística de las predicciones.

V. SIMULACIÓN MONTE CARLO

La simulación Monte Carlo representa el núcleo principal del proyecto.

El procedimiento implementado consiste en:

1. Generar probabilidades de resultado para cada partido.
2. Simular resultados utilizando distribuciones probabilísticas.
3. Ejecutar la fase de grupos.
4. Clasificar equipos según el reglamento FIFA 2026 [1].
5. Simular rondas eliminatorias.
6. Repetir el torneo miles de veces.

El equipo campeón de cada simulación fue registrado para estimar probabilidades finales de campeonato.

La simulación permitió modelar incertidumbre y variabilidad propias del fútbol internacional.

VI. RESULTADOS

Los resultados muestran que XGBoost obtuvo mejor desempeño probabilístico respecto a Regresión Logística.

Las variables con mayor capacidad predictiva fueron:

- Diferencia ELO
- Forma reciente
- Localía
- Decay temporal

La simulación Monte Carlo permitió estimar probabilidades realistas de campeonato para las selecciones participantes.

VII. LIMITACIONES

El proyecto presenta limitaciones inherentes a la naturaleza impredecible del fútbol profesional.

Entre las principales limitaciones se encuentran:

- Lesiones inesperadas
- Cambios tácticos
- Variabilidad emocional
- Datos incompletos
- Incertidumbre inherente al deporte

VIII. CONCLUSIONES

Se desarrolló un sistema predictivo basado en Machine Learning y simulación Monte Carlo orientado al Mundial FIFA 2026.

La combinación de ratings ELO, análisis histórico y modelos probabilísticos permitió construir un pipeline robusto para estimar probabilidades de resultado en partidos internacionales.

Como trabajo futuro, podrían incorporarse métricas avanzadas relacionadas con estadísticas de jugadores, análisis táctico y datos en tiempo real.

REFERENCIAS

- [1] FIFA, “FIFA World Rankings,” FIFA Official Website.
- [2] Kaggle, “International Football Results Dataset.”
- [3] EloRatings.net, “World Football Elo Ratings.”
- [4] T. Chen and C. Guestrin, “XGBoost: A Scalable Tree Boosting System,” Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 2016.
- [5] Scikit-learn Documentation, “Machine Learning in Python.”
- [6] FIFA, “FIFA World Cup 2026 Format.”
- [7] J. B. Heaton, “Introduction to Neural Networks and Machine Learning for Sports Prediction,” Journal of Sports Analytics.